

Nomlangan obyektlarni tanib olish (NER, Named Entity Recognition) tizimini yaratish.

Tabiiy tilni qayta ishlash — 10-ma'ruza

A.A. Abdulali

11:30–12:50 · mavzu №10

1-iyul 2026

Prezentatsiya rejasi

- 1 Kirish: matndan obyektlarni ajratamiz
- 2 NER(Named Entity Recognition) vazifasi va teglash sxemalari
- 3 LSTM asosidagi NER arxitekturasini
- 4 Bi-LSTM bilan kontekstni yaxshilash
- 5 NER samaradorligini baholash
- 6 Xulosa va amaliyotga ko'prik

Takrorlash: o'tgan darsdan ikki savol

1-savol

L9 da **Bi-LSTM** standart **tokenma-token generatsiya** uchun nega bevosita mos emas? *Maslahat: u qaysi kontekstni ham ko'radi?*

2-savol

Butun gap avvaldan ma'lum bo'lsa, chap va o'ng kontekst qaysi NLP vazifasida ayniqsa **foydali**?

Takrorlash: o'tgan darsdan ikki savol

1-savol

L9 da **Bi-LSTM** standart **tokenma-token generatsiya** uchun nega bevosita mos emas? *Maslahat: u qaysi kontekstni ham ko'radi?*

2-savol

Butun gap avvaldan ma'lum bo'lsa, chap va o'ng kontekst qaysi NLP vazifasida ayniqsa **foydali**?

1-javob

Generatsiyada keyingi tokenlar hali mavjud emas. Bi-LSTM esa chap kontekst bilan birga **o'ng kontekstni** ham ishlatadi. Shuning uchun u chapdan-o'ngga generatsiyada bevosita mos emas.

2-javob

Ketma-ketlikni teglashda (*sequence labeling*). Gap to'liq berilgan, model esa **har token uchun teg** bashorat qiladi. **NER** shunday vazifa.

Dars yakunida siz quyidagilarni bajara olasiz

- 1 **NER vazifasini** va **IOB2 teglash sxemasini** (B-/I-/O) tushuntira olasiz.
- 2 **IOB2 sxemasini qo'lda qo'llay olasiz**: “Malika Toshkentda ishlaydi .” → [B-PER, B-LOC, O, O].
- 3 **LSTM/Bi-LSTM asosidagi NER arxitekturasini** tushuntira olasiz: model har token uchun alohida teg bashorat qiladi.
- 4 **Entity-darajali precision, recall va F1** ko'rsatkichlarini hisoblay olasiz.

L7–L9 dan: LSTM va Bi-LSTM. L2 dan: precision, recall, F1. Matematikadan: nisbat va garmonik o'rtacha.

Bugungi dars rejasi

Bosqich	Mavzu	Darsdan chiqadigan natija
1	NER vazifasi va teglash sxemalari	[B-PER, B-LOC, 0, 0] ni tushunish
2	LSTM asosidagi NER arxitekturasini	har token uchun teg bashorat qilish
3	Bi-LSTM orqali kontekstni yaxshilash	chap va o'ng kontekstdan foydalanish
4	NER samaradorligini baholash	entity-darajali precision, recall va F1 ni hisoblash
Xulosa va 10-amaliyotga ko'prik		mini NER tagger qanday qurilishini ko'rish

Bugungi dars Bi-LSTM uchun tabiiy vazifani ko'rsatadi

L9 da Bi-LSTM standart tokenma-token generatsiya uchun bevosita mos emasligini ko'rdik. Bugun esa butun gap avvaldan ma'lum bo'lgan **ketma-ketlikni teglash** vazifasida undan qanday foydalanishni ko'ramiz.

Bugungi muammo: matndagi nomlangan obyektlarni qanday topamiz?

Sodda yondashuv qayerda qiynaladi?

Lug'at qidiruvi yetarli emas

Tayyor ismlar ro'yxati **yangi nomlarni** topa olmaydi va kontekstni hisobga olmaydi: Olma — ismimi yoki meva?

Qo'shimchalar chegarani aniqlashni qiyinlashtiradi

Toshkentda = Toshkent + -da. Sodda tokenlash joy nomi qayerda boshlanib, qayerda tugashini noto'g'ri belgilashi mumkin.

Bugungi yechim

- 1 NER ni **ketma-ketlikni teglash** (*sequence labeling*) vazifasi deb qaraymiz: har token uchun teg beriladi.
- 2 **IOB2** sxemasi nomlangan obyektning **boshi** va **davomini** aniq belgilaydi.
- 3 **Bi-LSTM** teg tanlashda chap va o'ng kontekstdan foydalanadi.

Natija: model faqat lug'atga emas, balki **kontekstga** ham tayanib nomlangan obyektlarni topadi.

Prezentatsiya rejasi

- 1 Kirish: matndan obyektlarni ajratamiz
- 2 **NER(Named Entity Recognition) vazifasi va teglash sxemalari**
- 3 LSTM asosidagi NER arxitekturasini
- 4 Bi-LSTM bilan kontekstni yaxshilash
- 5 NER samaradorligini baholash
- 6 Xulosa va amaliyotga ko'prik

Intuitsiya: har tokenning matndagi “roli”ni topamiz

NER (*Named Entity Recognition*) — matndagi **nomlangan obyektlarni** topish va ularning turini aniqlash.

- **PER** — shaxs (*person*): Malika, Akmal
- **LOC** — joy (*location*): Toshkent, Samarqand
- **ORG** — tashkilot (*organization*): BMT, universitet

NER — **ketma-ketlikni teglash** (*sequence labeling*)
vazifasi: model har bir token uchun bitta teg tanlaydi.

Oddiy misol

Token	Rol/teg
Malika	PER
Toshkentda	LOC
ishlaydi	O

Muammo: nomlangan obyekt bir nechta tokenidan iborat bo'lishi mumkin: “Toshkent shahri”. Boshini va davomini qanday ajratamiz?

Keyingi qadam: IOB2 sxemasi.

Umumiy nomlangan obyekt turlari va o'zbekcha misollar

Teg	Ma'nosi	O'zbekcha misol
PER	shaxs (<i>person</i>)	Malika, Akmal, Aliyev
LOC	joy (<i>location</i>)	Toshkent, Samarqand, Amudaryo
ORG	tashkilot (<i>organization</i>)	BMT, Artel, Toshkent davlat univer- siteti
DATE	sana/vaqt ifodasi (<i>date/time</i>)	2026-yil, dushanba, 10-mart
MISC	boshqa maxsus nomlar (<i>miscellaneous</i>)	o'zbek tili, "Alpomish" dostoni

Teglar to'plami vazifa va korpusga bog'liq

Turkumlar doimo bir xil bo'lavermaydi: masalan, CoNLL-2003 uslubida PER/LOC/ORG/MISC ishlatiladi, boshqa korpuslarda DATE, TIME, MONEY kabi teglar ham bo'lishi mumkin.

Asosiy g'oya o'zgarmaydi: **har token uchun bitta teg** tanlanadi, nomlangan obyekt esa bir yoki bir nechta tokenidan iborat bo'lishi mumkin. Shuning uchun keyingi qadamda **chegarani belgilash** sxemasi kerak bo'ladi.

IOB2 teglash sxemasi: rasmiy ta'rif

- B-XXX — nomlangan obyektning **boshi** (*Begin*), turi XXX.
- I-XXX — shu obyektning **davomi** (*Inside*), turi XXX.
- O — nomlangan obyekt **emas** (*Outside*).

Bu yerda XXX — obyekt turi: PER, LOC, ORG va hokazo.

Muhim qoida

IOB2 da **har bir** nomlangan obyekt B- tegi bilan boshlanadi.

I-XXX esa faqat avval boshlangan shu turdagi obyektни davom ettiradi.

Misol

“Toshkent shahri” — ikki tokenli bitta joy nomi:

Toshkent shahri

B-LOC I-LOC

Demak, IOB2 tegi bir vaqtning o'zida ikki ma'lumotni beradi: **obyekt chegarasi** va **obyekt turi**.

Nega oddiy PER/LOC/O yetarli emas?

Muammo: chegara ko'rinmaydi

Faqat obyekt turi berilsa, ketma-ket kelgan ikkita LOC tokenini qanday ajratish noaniq bo'lib qoladi:


LOC LOC

Bu **ikkita alohida joy**mi yoki **bitta ko'p tokenli joy nomi**mi?

Yechim: B-/I- ajratuvi

B- obyekt **boshini**, I- esa uning **davomini** bildiradi.

Shuning uchun IOB2 tegi ikkita ma'lumotni birlashtiradi: **chegara + tur**.



IOB2 qoidasining mazmuni: har bir nomlangan obyekt B- bilan boshlanadi; shu obyekt davom etsa, keyingi tokenlar I- bilan belgilanadi.

Qo'lda misol: IOB2 teglash — [B-PER, B-LOC, 0, 0]

Tokenlar: [Malika, Toshkentda, ishlaydi, .]

Token	Tahlil	IOB2 tegi
Malika	shaxs nomi, obyekt boshi	B-PER
Toshkentda	joy nomi + -da qo'shimchasi	B-LOC
ishlaydi	fe'l, nomlangan obyekt emas	0
.	tinish belgisi, nomlangan obyekt emas	0

Muhim izoh

Word-level teglashda Toshkentda bitta token sifatida B-LOC bo'ladi: u joy nomi bilan boshlanadi.

Agar aniq matn chegarasi kerak bo'lsa, Toshkent + -da kabi morfologik ajratish alohida ko'riladi.

10-amaliyotda shu misol quyidagicha tekshiriladi:

```
tags ==  
[B-PER, B-LOC, 0, 0]
```

Sizning vazifangiz: ikki tokenli joy nomini teglash

Savol

Gap: “Akmal Navoiy shahrida yashaydi”.

Tokenlar: [Akmal, Navoiy, shahrida, yashaydi].

IOB2 teglari qanday bo'ladi?

Maslahat: bu misolda “Navoiy shahrida” bitta joy nomi sifatida olinadi, ya'ni ikki tokenli LOC.

Sizning vazifangiz: ikki tokenli joy nomini teglash

Savol

Gap: “Akmal Navoiy shahrida yashaydi”.

Tokenlar: [Akmal, Navoiy, shahrida, yashaydi].

IOB2 teglari qanday bo'ladi?

Maslahat: bu misolda “Navoiy shahrida” bitta joy nomi sifatida olinadi, ya'ni ikki tokenli LOC.

Javob

To'g'ri javob:

[B-PER, B-LOC, I-LOC, 0]

- Akmal — shaxs nomi: B-PER.
- Navoiy — joy nomining boshi: B-LOC.
- shahrida — joy nomining davomi: I-LOC.
- yashaydi — nomlangan obyekt emas: 0.

Ikki tokenli nomlangan obyekt B- bilan boshlanadi va I- bilan davom etadi.

Kod ↔ tushuncha: IOB2 teglar

```
# teglangan jumla: (token, teg) juftlari
```

```
sentence = [  
    ("Malika",      "B-PER"),  
    ("Toshkentda", "B-LOC"),  
    ("ishlaydi",    "O"),  
    (".",           "O"),  
]
```

```
tags = [tag for _, tag in sentence]  
print(tags)
```

```
# ['B-PER', 'B-LOC', 'O', 'O']
```

```
TAGSET = [  
    "O",  
    "B-PER", "I-PER",  
    "B-LOC", "I-LOC",  
    "B-ORG", "I-ORG",  
]
```

Koddan olinadigan g'oya

- B-PER — shaxs nomining boshi.
- I-LOC — joy nomining davomi.
- O — nomlangan obyekt emas.

Amaliyotga bog'lanish

10-amaliyotda NER modeli ma'lumotni aynan shunday (token, teg) juftliklari ko'rinishida o'qiydi. TAGSET esa model tanlashi mumkin bo'lgan barcha teglar ro'yxatini bildiradi.

BIOES sxemasi: chegarani aniqroq belgilash

IOB2 dagi B-, I-, O teglari saqlanadi. BIOES esa yana ikki chegara tegini qo'shadi:

- E-XXX — nomlangan obyektning **oxiri** (*End*);
- S-XXX — **yakka tokenli** obyekt (*Single*).

Natijada model obyekt qayerda **boshlanishi**, **davom etishi** va **tugashini** aniqroq ko'radi.

Bir xil obyekt, ikki xil sxema

“Birlashgan Millatlar Tashkiloti”:

IOB2:

B-ORG I-ORG I-ORG

BIOES:

B-ORG I-ORG E-ORG

“Malika” — yakka tokenli shaxs nomi:

IOB2: B-PER **BIOES:** S-PER

Afzallik va narx

BIOES chegarani aniqroq kodlaydi, shuning uchun ba'zi NER tajribalarida F1 ni oshirishi mumkin. Lekin teglar soni ko'payadi, kam uchraydigan teglar siyraklashadi va natija korpusga bog'liq bo'ladi. Shu kursda asosiy sxema sifatida **IOB2** ishlatiladi.

Teglash tuzog'i: noto'g'ri teg ketma-ketligi

Noto'g'ri ketma-ketlik

IOB2 da quyidagi holat mantiqan noto'g'ri:

O I-L0C

I-L0C avval boshlangan L0C obyektini davom ettirishi kerak. O esa oldin obyekt yo'qligini bildiradi.

Oddiy LSTM-NER modelida har token uchun teg alohida tanlanadi.

Shuning uchun model ba'zan **teglar orasidagi o'tish qoidasini** buzishi mumkin.

Yechim

Bunday xatoni kamaytirish uchun **CRF** (*Conditional Random Field*) qatlami yoki oddiy post-protsessing qoidalari ishlatiladi.

Prezentatsiya rejasi

- 1 Kirish: matndan obyektlarni ajratamiz
- 2 NER(Named Entity Recognition) vazifasi va teglash sxemalari
- 3 LSTM asosidagi NER arxitekturasini**
- 4 Bi-LSTM bilan kontekstni yaxshilash
- 5 NER samaradorligini baholash
- 6 Xulosa va amaliyotga ko'prik

Intuitsiya: har token uchun teg bashorat qilamiz

Oddiy tasniflashda butun gapga **bitta yorliq** beriladi:

gap $\rightarrow$ bitta sinf

NER da esa har bir token uchun **alohida teg** bashorat qilinadi:

token_t $\rightarrow$ teg_t

NER oqimi

Har token avval vektor ko'rinishga o'tkaziladi (*embedding*), keyin LSTM kontekstni hisobga oladi:

$x_t \rightarrow e_t \rightarrow h_t \rightarrow \hat{y}_t$


Bu yerda $\hat{y}_t$ — t -token uchun teglar bo'yicha ehtimol taqsimoti.

NER — **token-darajali ketma-ketlikni teglash** vazifasi. Butun gap oldindan berilgani uchun keyingi slaydlarda Bi-LSTM orqali chap va o'ng kontekstdan foydalanamiz.

LSTM-NER: rasmiy ta'rif

$$h_t = \text{LSTM}(x_t, h_{t-1}), \quad \hat{y}_t = \text{softmax}(Wh_t + b)$$

Bu yerda: x_t — t -tokenning vektor ko'rinishi (*embedding*); h_t — kontekstni yig'uvchi yashirin holat; W, b — chiqish qatlaminig parametrlari; $\hat{y}_t$ — teglar ustidan ehtimol taqsimoti. Amalda **eng katta ehtimolli teg** tanlanadi.



Asosiy g'oya: har bir token uchun **alohida chiqish** hosil bo'ladi, lekin bu chiqish **so'z emas**, balki **teglar ustidan ehtimol taqsimoti**. Shuning uchun NER — **token-darajali ketma-ketlikni teglash** vazifasi.


Keltirib chiqarish: token holatidan tegga

1-qadam: LSTM har token uchun kontekstli holat beradi: h_t . **2-qadam:** h_t teglar soniga proyeksiya qilinadi:

$$z_t = Wh_t + b, \quad z_t \in \mathbb{R}^{|\text{TAGSET}|}.$$

3-qadam: softmax teglar ehtimolini beradi:

$$\hat{y}_t = \text{softmax}(z_t), \quad \text{teg}_t = \arg \max_k \hat{y}_{t,k}.$$



Xulosa: bu oddiy softmax tasnifi, lekin bitta gap uchun emas, **har token uchun alohida** bajariladi.

Qo'lda misol: bitta token uchun teg tanlash


TAGSET = [0, B-PER, B-LOC], ballar (logitlar) $z = [0.0, 2.0, 1.0]$.

Softmax va tanlov

$$\begin{aligned}\hat{y} &= \text{softmax}(z) \\ &= \frac{[e^0, e^2, e^1]}{e^0 + e^2 + e^1} \\ &\approx \frac{[1.00, 7.39, 2.72]}{11.11} \\ &\approx [0.090, \mathbf{0.665}, 0.245]\end{aligned}$$

$$\arg \max \hat{y} = \text{B-PER}$$

Demak, eng katta ehtimol B-PER tegiga tegishli.



Sizning vazifangiz: boshqa token uchun teg

Savol

TAGSET = [0, B-PER, B-LOC].

Token: ishlaydi, ballar (logitlar): $z = [3.0, 1.0, 0.0]$.

Qaysi teg tanlanadi?

Sizning vazifangiz: boshqa token uchun teg

Savol

TAGSET = [0, B-PER, B-LOC].

Token: ishlaydi, ballar (logitlar): $z = [3.0, 1.0, 0.0]$.

Qaysi teg tanlanadi?

Javob

Eng katta ball 0 tegiga tegishli:

$$z_0 = 3.0 \quad \Rightarrow \quad \arg \max z = 0.$$

Softmax tartibni o'zgartirmaydi: eng katta logit eng katta ehtimolga ega bo'ladi. Bu gapda ishlaydi fe'l, ya'ni nomlangan obyekt emas. Shuning uchun tanlangan teg: 0.

Kod $\leftrightarrow$ formula: per-token teglash

```
import torch.nn as nn

class NERModel(nn.Module):
    def __init__(self, vocab, dim, hid, n_tags):
        super().__init__()
        self.emb = nn.Embedding(vocab, dim)
        self.lstm = nn.LSTM(dim, hid, batch_first=True)
        self.fc = nn.Linear(hid, n_tags)
    def forward(self, x):
        e = self.emb(x)           # (B, T, dim)
        out, _ = self.lstm(e)     # (B, T, hid)
        logits = self.fc(out)    # (B, T, n_tags)
        return logits
```

$\text{emb}(x): x_t \rightarrow e_t$
 $\text{lstm}(e): e_t \rightarrow h_t$
 $\text{fc}(\text{out}): z_t = Wh_t + b$

Asosiy farq

Gap tasnifida oxirgi holat h_T ishlatiladi. NER da esa out dagi **har token holati**: $(B, T, \text{hid}) \rightarrow (B, T, n_tags)$.

Eslatma: model logits qaytaradi. Teg ehtimoli kerak bo'lsa, softmax qo'llanadi: $\hat{y}_t = \text{softmax}(z_t)$.

Arxitektura tuzog'i: bir tomonlama kontekst yetishmaydi

Muammo: o'ng kontekst ham kerak

Bir tomonlama LSTM tokenni teglashda asosan **chap kontekst**ga tayanadi.

Masalan, Navoiy tokenining turi keyingi so'zga bog'liq bo'lishi mumkin:

- Navoiy shahrida $\Rightarrow$ LOC
- Navoiy g'azali $\Rightarrow$ PER

Demak, ayrim hollarda to'g'ri teg uchun **o'ng kontekst** zarur.

Yechim: Bi-LSTM

Bi-LSTM tokenni ikki tomondan ko'radi:

chap kontekst + o'ng kontekst

Shuning uchun u NER'da ko'p tokenli va kontekstga bog'liq obyektlarni aniqroq teglashga yordam beradi.

Prezentatsiya rejasi

- 1 Kirish: matndan obyektlarni ajratamiz
- 2 NER(Named Entity Recognition) vazifasi va teglash sxemalari
- 3 LSTM asosidagi NER arxitekturasini
- 4 Bi-LSTM bilan kontekstni yaxshilash**
- 5 NER samaradorligini baholash
- 6 Xulosa va amaliyotga ko'prik

Intuitsiya: teglashda butun gapdan foydalanamiz

NER generatsiya emas: gap odatda oldindan to'liq berilgan bo'ladi.

Shuning uchun model tokenni teglashda faqat chap kontekstni emas, **o'ng kontekst**ni ham ishlatishi mumkin.

Har token uchun birlashtirilgan holat

$$h_t = [\vec{h}_t; \overleftarrow{h}_t]$$

$\vec{h}_t$ — chapdan kelgan kontekst, $\overleftarrow{h}_t$ — o'ngdan kelgan kontekst.

Misol

Navoiy tokenini teglashda o'ng kontekst muhim bo'lishi mumkin:

Navoiy shahrida

⇒ LOC

Navoiy g'azali


⇒ PER

Demak, keyingi so'z teg tanlashga yordam beradi.

Bi-LSTM NER: rasmiy ta'rif

$$h_t = [\vec{h}_t; \overleftarrow{h}_t], \quad \hat{y}_t = \text{softmax}(Wh_t + b)$$

Bu yerda: $\vec{h}_t$ — chapdan kelgan kontekst, $\overleftarrow{h}_t$ — o'ngdan kelgan kontekst, $[\ ; \]$ — birlashtirish. Agar har yo'nalish holati o'lchami d_h bo'lsa, unda $h_t \in \mathbb{R}^{2d_h}$, shuning uchun $W \in \mathbb{R}^{|\text{TAGSET}| \times 2d_h}$.




Xulosa: Bi-LSTM har tokenni teglashda **chap va o'ng kontekst**ni birga ishlatadi. Shu sababli u ko'pincha oddiy bir yo'nalishli LSTM ga nisbatan NER uchun foydaliroq bo'ladi.

Nega NER generatsiyadan farqli ishlaydi?


1. Chapdan-o'ngga generatsiyada t qadamda kelajak tokenlar ($x_{t+1}, x_{t+2}, \dots$) hali mavjud emas.
2. NER da esa butun gap oldindan beriladi.
3. Shuning uchun NER da chap va o'ng kontekstni birlashtirish mumkin:

$$h_t = [\vec{h}_t; \overleftarrow{h}_t].$$

Generatsiya (L9)



NER teglash



Xulosa: NER da onlayn generatsiyadagi **sababiyat cheklovi** yo'q, shuning uchun **Bi-LSTM** teglash uchun mos arxitektura hisoblanadi.

Qo'lda misol: chap va o'ng kontekstni birlashtiramiz

$$\vec{h}_t = [0.2, 0.8], \quad \overleftarrow{h}_t = [0.9, 0.1].$$

Bu yerda har bir yo'nalish holati o'lchami 2.


Birlashtirish:

$$h_t = [\vec{h}_t; \overleftarrow{h}_t] = [0.2, 0.8, 0.9, 0.1]$$

O'lcham: $2 + 2 = 4$. Demak, token holati chap va o'ng kontekst ma'lumotini birga saqlaydi.

Kontekst nima uchun kerak?

Navoiy tokenining tegi o'ng kontekstga qarab aniqlanadi: Navoiy shahriga $\Rightarrow$ LOC, ammo Navoiy g'azali $\Rightarrow$ PER. Shuning uchun Bi-LSTM o'ng kontekstdan ham foydalanadi.



Sizning vazifangiz: birlashtirilgan holat o'lchami

Savol

Agar Bi-LSTM da har bir yo'nalish holati **64 o'lchamli** bo'lsa:

$$\vec{h}_t \in \mathbb{R}^{64}, \quad \overleftarrow{h}_t \in \mathbb{R}^{64}$$

Birlashtirilgan h_t o'lchami nechta?

Sizning vazifangiz: birlashtirilgan holat o'lchami

Savol

Agar Bi-LSTM da har bir yo'nalish holati **64 o'lchamli** bo'lsa:

$$\vec{h}_t \in \mathbb{R}^{64}, \quad \overleftarrow{h}_t \in \mathbb{R}^{64}$$

Birlashtirilgan h_t o'lchami nechta?

Javob

$$h_t = [\vec{h}_t ; \overleftarrow{h}_t] \in \mathbb{R}^{64+64} = \mathbb{R}^{128}$$

Demak, birlashtirilgan holat o'lchami **128** bo'ladi. Shuning uchun chiqish qatlami `Linear(128, n_tags)` ko'rinishida olinadi.

Kod $\leftrightarrow$ formula: Bi-LSTM NER

```
import torch.nn as nn

class BiLSTMNER(nn.Module):
    def __init__(self, vocab, dim, hid, n_tags):
        super().__init__()
        self.emb = nn.Embedding(vocab, dim)
        self.lstm = nn.LSTM(
            input_size=dim,
            hidden_size=hid,
            batch_first=True,
            bidirectional=True)
        self.fc = nn.Linear(2 * hid, n_tags)

    def forward(self, x):
        e = self.emb(x)           # (B, T, dim)
        out, _ = self.lstm(e)     # (B, T, 2*hid)
        logits = self.fc(out)    # (B, T, n_tags)
        return logits
```

bidirectional=True: $\vec{h}_t, \overleftarrow{h}_t$

Birlashtirilgan holat:

$$h_t = [\vec{h}_t; \overleftarrow{h}_t]$$

Chiqish qatlami: $z_t = Wh_t + b$

Esda tuting

Har yo'nalish o'lchami hid bo'lsa, Bi-LSTM chiqishi $2*hid$ bo'ladi. Shuning uchun $Linear(2*hid, n_tags)$.

Model har token uchun **logitlar** qaytaradi: (B, T, n_tags) . Teg ehtimoli kerak bo'lsa, softmax qo'llanadi: $\hat{y}_t = \text{softmax}(z_t)$.

Bi-LSTM tuzog'i: chiqish o'lchamini unutish

Eng ko'p uchraydigan xato

Bi-LSTM da `bidirectional=True` qo'yiladi, lekin chiqish qatlami eski o'lchamda qoldiriladi:

```
nn.Linear(hid, n_tags)
```

Bu xato beradi, chunki Bi-LSTM chiqishi `hid` emas, `2*hid` o'lchamli bo'ladi.

To'g'ri variant

Har yo'nalish holati `hid` bo'lsa:

$$h_t = [\vec{h}_t; \overleftarrow{h}_t] \in \mathbb{R}^{2 \cdot hid}$$

Shuning uchun chiqish qatlami:

```
nn.Linear(2*hid, n_tags)
```

Yodda tuting: oddiy LSTM chiqishi `hid`; Bi-LSTM chiqishi esa `2*hid`. Bu NER modelida `fc` qatlamini yozishda eng muhim joy.

Prezentatsiya rejasi

- 1 Kirish: matndan obyektlarni ajratamiz
- 2 NER(Named Entity Recognition) vazifasi va teglash sxemalari
- 3 LSTM asosidagi NER arxitekturasini
- 4 Bi-LSTM bilan kontekstni yaxshilash
- 5 NER samaradorligini baholash**
- 6 Xulosa va amaliyotga ko'prik

Intuitsiya: to'g'ri obyekt = chegara + tur

NER da nomlangan obyekt **to'g'ri** sanalishi uchun ikkala shart bajarilishi kerak:

- **chegara** to'g'ri: obyekt qayerdan boshlanib, qayerda tugashi;
- **tur** to'g'ri: PER, LOC, ORG va hokazo.

Nega token-level accuracy yetarli emas?

Matnda 0 teglari ko'p bo'ladi. Model 0 larni yaxshi topsa ham, asl nomlangan obyektlarni yomon topishi mumkin.

Kichik misol

Gold javob:

Toshkent shahri $\Rightarrow$ LOC

Model javobi:

Toshkent $\Rightarrow$ LOC

Tur to'g'ri, lekin chegara to'liq emas.
Shuning uchun entity-darajada bu **xato**.

Baholashda nima ishlatiladi?

Keyingi slaydlarda oldingi metrikalarni qayta emas, **NERga mos ko'rinishda** ishlatamiz: entity-darajali **precision, recall, F1**. sequeval buni hisoblashda keng ishlatiladi.

Entity-darajali F1: rasmiy ta'rif

$$P = \frac{TP}{TP + FP}, \quad R = \frac{TP}{TP + FN}, \quad F_1 = \frac{2PR}{P + R}$$

NER uchun muhim nuqta: bu yerda **TP**, **FP**, **FN** lar **token** bo'yicha emas, **entity** bo'yicha sanaladi.

Entity-darajali sanash


TP — model to'g'ri topgan obyekt (chegara **ham**, tur **ham** to'g'ri).

FP — model ortiqcha yoki noto'g'ri bashorat qilgan obyekt.

FN — gold ro'yxatda bor, lekin model topmagan obyekt.

Muhim eslatma

Qisman moslik yetarli emas: **chegara xato** yoki **tur xato** bo'lsa, bu entity-darajada **xato** hisoblanadi.



Farqi formulada emas: bu yerda baholash **to'liq span + tur** bo'yicha qilinadi.

Entity-darajali sanash: TP, FP, FN

Har bir bashorat qilingan nomlangan obyekt gold obyektlar bilan solishtiriladi: **span** va **tur** bir xil bo'lsa — **TP**.

Bashoratda bor, lekin gold bilan mos kelmasa — **FP**. Goldda bor, lekin model topmasa — **FN**.



Strict entity-level baholash

Agar obyektning **chegarasi** yoki **turi** xato bo'lsa, u TP emas. Masalan, gold Toshkent shahri/L0C, model Toshkent/L0C desa, chegara to'liq emas: bu entity-darajada xato.

Qo'lda misol: entity-darajali $F_1 = 0.5$

Gold: {(Malika, PER), (Toshkent, LOC)}

Bashorat: {(Malika, PER), (Toshkent, ORG)}.

Sanash


- (Malika, PER) mos $\Rightarrow TP = 1$
- (Toshkent, ORG) tur xato $\Rightarrow FP = 1$
- (Toshkent, LOC) gold da bor, topilmadi $\Rightarrow FN = 1$

$$P = \frac{TP}{TP + FP} = \frac{1}{2}, \quad R = \frac{TP}{TP + FN} = \frac{1}{2}$$

$$F_1 = \frac{2PR}{P + R} = \frac{2 \cdot 0.5 \cdot 0.5}{0.5 + 0.5} = 0.5$$

Gold

Bashorat



Toshkent ning **chegarasi** mos, lekin **turi** xato (LOC o'rniga ORG). Shuning uchun bu strict entity-darajada **TP emas**: bitta **FP** va bitta **FN** hosil bo'ladi.

Sizning vazifangiz: hammasi to'g'ri bo'lsa

Savol

Gold va bashorat bir xil:

$\{(Malika, PER), (Toshkent, LOC)\}$

Ikkala nomlangan obyekt ham chegara va turi bo'yicha to'g'ri.

TP, FP, FN va F_1 qancha?

Sizning vazifangiz: hammasi to'g'ri bo'lsa

Savol

Gold va bashorat bir xil:

$\{(Malika, PER), (Toshkent, LOC)\}$

Ikkala nomlangan obyekt ham chegara va turi bo'yicha to'g'ri.

TP , FP , FN va F_1 qancha?

Javob

$$TP = 2, \quad FP = 0, \quad FN = 0.$$

$$P = \frac{TP}{TP + FP} = \frac{2}{2} = 1.0, \quad R = \frac{TP}{TP + FN} = \frac{2}{2} = 1.0.$$

$$F_1 = \frac{2PR}{P + R} = \frac{2 \cdot 1.0 \cdot 1.0}{1.0 + 1.0} = 1.0.$$

Demak, barcha entitylar to'liq mos: **chegara ham, tur ham to'g'ri.**

Kod $\leftrightarrow$ formula: segeval bilan baholash

```
from segeval.metrics import (
    f1_score,
    classification_report
)

gold = [["B-PER", "B-LOC", "0", "0"]]
pred = [["B-PER", "B-ORG", "0", "0"]]

print(f1_score(gold, pred))    # 0.5
print(classification_report(gold, pred))
```

gold — haqiqiy teglar.

pred — model bashorat qilgan teglar.

Tashqi [] — gaplar ro'yxati,

ichki [] — bitta gapdagi teglar ketma-ketligi.

Nima hisoblanadi?

segeval BIO/IOB2 teglardan entity spanlarni ajratadi.

Keyin token accuracy emas, **entity-darajali** precision, recall va F_1 ni hisoblaydi.

Baholash tuzog'i: token-darajali aniqlik chalg'itadi

Yuqori accuracy, lekin yomon NER

NER ma'lumotida tokenlarning katta qismi 0 bo'lishi mumkin.

Agar model hamma tokenni 0 deb belgilasa, token-darajali aniqlik yuqori ko'rinishi mumkin:

$$\text{accuracy} \approx 0.9$$

Lekin model birorta nomlangan obyekt topmaydi. Agar gold da entitylar bor bo'lsa, entity-darajali $F_1 = 0$.

To'g'ri baholash

Asosiy natijani token accuracy bilan emas, **entity-darajali** metrikalar bilan bering:

$$P, \quad R, \quad F_1$$

Amaliyotda sequeval BIO/IOB2 teglardan entity spanlarni ajratib, entity-darajali precision, recall va F_1 ni hisoblaydi.

Prezentatsiya rejasi

- 1 Kirish: matndan obyektlarni ajratamiz
- 2 NER(Named Entity Recognition) vazifasi va teglash sxemalari
- 3 LSTM asosidagi NER arxitekturasini
- 4 Bi-LSTM bilan kontekstni yaxshilash
- 5 NER samaradorligini baholash
- 6 Xulosa va amaliyotga ko'prik

O'zbek tilida NER: qo'shimchalar va resurs cheklovi

1. Joy nomi + qo'shimcha

Toshkentda, Samarqanddan kabi shakllarda joy nomi kelishik qo'shimchasi bilan bitta token bo'lib kelishi mumkin.

Ehtiyot bo'ladigan joy

Word-level teglashda bunday token odatda B-LOC deb olinadi.

Agar subword (*so'zosti*) tokenizatsiya ishlatilsa, yorliqni subwordlarga qanday taqsimlash annotatsiya va trening strategiyasiga bog'liq bo'ladi.

2. Kam-resurslilik va domen

O'zbek NER uchun natija ko'pincha teglangan korpus hajmi, domeni va tokenizatsiya sifatiga kuchli bog'liq bo'ladi.

Realistik baho

Modelni faqat token-accuracy bilan baholash yetarli emas.

Asosiy natijani **entity-darajali** precision, recall va F_1 bilan beramiz: bunda obyektning **chegarasi ham, turi ham** to'g'ri bo'lishi kerak.

Etika: NER natijalari mas'uliyat bilan ishlatiladi

Maxfiylik xavfi

NER hujjatlardan **shaxs nomlari**, manzil, tashkilot va boshqa shaxsga oid ma'lumotlarni avtomatik ajratishi mumkin.

Bu ma'lumotlar roziliksiz ishlatilsa yoki noto'g'ri saqlansa, maxfiylik buzilishi mumkin.

Xato ajratish oqibati

Noto'g'ri topilgan yoki o'tkazib yuborilgan nomlangan obyekt hujjat tahlilida xato xulosaga olib kelishi mumkin.

Bu ayniqsa huquqiy, tibbiy yoki rasmiy matnlarda muhim.

Mas'uliyatli qo'llash

- Qaysi domen va tilda model ko'proq xato qilishi mumkinligini hujjatlashtirish.
- Muhim qararlarda inson nazoratini saqlash (*human-in-the-loop*).
- Natijani token-accuracy bilan emas, **entity-darajali** precision, recall va F_1 bilan tekshirish.
- Maxfiy ma'lumotlar uchun rozilik, minimallashtirish va himoyalash qoidalariga rioya qilish.

Sintez: teglash sxemalari va baholash

Sxema	Teglar	Qisqa izoh
IOB1	I-, B-, O	B- asosan qo'shni obyektlarni ajratish uchun ishlatiladi.
IOB2	B-, I-, O	Har bir nomlangan obyekt B- bilan boshlanadi (kurs tanlovi).
BIOES	B-, I-, O, E-, S-	Chegarani aniqroq bildiradi, lekin teglar soni ko'payadi.

Asosiy g'oya

NER — **ketma-ketlikni teglash** vazifasi:

IOB2 teglash + Bi-LSTM konteksti + entity-darajali $P/R/F_1$.

O'zbek tilida asosiy qiyinchiliklar: **qo'shimchali so'z shakllari**, tokenizatsiya va **kam teglangan ma'lumot**.

Muhim manba: Lample va boshqalar (2016)

Lample, G., Ballesteros, M., Subramanian, S., Kawakami, K., Dyer, C. (2016). **Neural Architectures for Named Entity Recognition**. *NAACL-HLT 2016*.

Nima uchun muhim?

- **Bi-LSTM-CRF** arxitekturasini NER uchun kuchli neyron baseline sifatida ommalashtirdi.
- So'z ichidagi belgilarni ham ishlatdi: character-level model nomlarning shaklini yaxshiroq ushlaydi (-ov, -eva, bosh harf va hokazo).
- **CRF** qatlami ketma-ket teglar orasidagi o'tishlarni hisobga oladi va noto'g'ri teg ketma-ketliklarini kamaytiradi.
- Bu yondashuv keyingi NER modellarini taqqoslash uchun qulay klassik neyron baseline bo'lib qoldi.

Muhokama savoli

O'zbek NER uchun teglangan ma'lumot kam va domenlar farq qiladi. Bunday sharoitda sifatni qanday oshirish mumkin?

Maslahat: transfer learning, ko'p tilli BERT/XLM-R, domen moslashtirish.

Bugungi maqsadlar bajarildi

① ✓ **NER vazifasini va IOB2 teglash sxemasini** (B-/I-/O) tushuntirdik.

② ✓ **IOB2 sxemasini qo'lda qo'lladik:** “Malika Toshkentda ishlaydi”

→ [B-PER, B-LOC, O, O].

③ ✓ **LSTM/Bi-LSTM asosidagi NER arxitekturasini** tushuntirdik: model har token uchun alohida teg bashorat qiladi.

④ ✓ **Bi-LSTM da o'lcham o'zgarishini** ko'rdik: birlashtirilgan holat o'lchami $2 \times \text{hidden}$ bo'ladi.

⑤ ✓ **Entity-darajali baholashni** qo'lladik: strict match, precision/recall/F1 va tur xatosida $F_1 = 0.5$ misoli.

Keyingi ma'ruza (L11): teglashdan tarjimaga

Bugungi dars: NER

NER — **ketma-ketlikni teglash** (*sequence labeling*) vazifasi:

har token $\rightarrow$ bitta teg

Kirish va chiqish uzunligi bir xil:

$$n \rightarrow n$$

Keyingi dars: tarjima


Mashina tarjimasida chiqish uzunligi boshqacha bo'lishi mumkin:

Men kitob o'qidim $\rightarrow$ I read a book


$$3 \rightarrow 4$$

L11 da **Seq2Seq** (*Sequence-to-Sequence*) arxitekturasini ko'riladi: encoder kirish gapni o'qiydi, decoder esa yangi chiqish gapni generatsiya qiladi.

NER: $n \rightarrow n$




Seq2Seq: $n \rightarrow m$



Farq: NER mavjud tokenlarga teg beradi; Seq2Seq esa yangi tokenlar ketma-ketligini yaratadi.

Keyingi amaliyot (P10): Bi-LSTM bilan NER tizimini qurish



P10 da qurasiz

- NERTagger: Embedding + Bi-LSTM + chiziqli chiqish qatlami.
- IOB2/BIO formatdagi teglangan korpusda modelni o'qitish.
- Natijani sequeval orqali entity-darajali F_1 bilan baholash.
- IOB2 teglash natijasini kichik assertlar bilan tekshirish.

L10 dagi qo'lda teglash misoli kodda ham shunday chiqishi kerak:

```
assert tags == [  
    "B-PER", "B-LOC",  
    "O", "O"  
]
```

Bu tekshiruv modeldan oldin IOB2 teglash mantiqi to'g'ri tuzilganini tekshiradi.

- ① Lample, G., Ballesteros, M., Subramanian, S., Kawakami, K., Dyer, C. (2016). *Neural Architectures for Named Entity Recognition*. NAACL-HLT 2016, pp. 260–270.
- ② Huang, Z., Xu, W., Yu, K. (2015). *Bidirectional LSTM-CRF Models for Sequence Tagging*. arXiv:1508.01991.
- ③ Ramshaw, L., Marcus, M. (1995). *Text Chunking using Transformation-Based Learning*. Third Workshop on Very Large Corpora.
- ④ Pan, X., Zhang, B., May, J., Nothman, J., Knight, K., Ji, H. (2017). *Cross-lingual Name Tagging and Linking for 282 Languages*. ACL 2017.
- ⑤ Nakayama, H. (2018). *seqeval: A Python framework for sequence labeling evaluation*.

Ilova S1: nega CRF qatlami qo'shiladi?

Per-token **softmax** har token tegini **mustaqil** tanlaydi. Shu sabab $0 \rightarrow \text{I-LOC}$ kabi **noto'g'ri o'tishlar** ham chiqishi mumkin. **CRF** (*Conditional Random Field*) esa **butun teg ketma-ketligini** baholaydi.

$$\text{score}(\mathbf{x}, \mathbf{y}) = \sum_t \left(s_t(y_t) + T(y_{t-1}, y_t) \right), \quad P(\mathbf{y} | \mathbf{x}) = \frac{\exp(\text{score}(\mathbf{x}, \mathbf{y}))}{\sum_{\mathbf{y}'} \exp(\text{score}(\mathbf{x}, \mathbf{y}'))}$$

Bu yerda $s_t(y_t)$ — Bi-LSTM dan kelgan **emission balli**, $T(y_{t-1}, y_t)$ — teglar orasidagi **o'tish balli**. Model $\text{B-LOC} \rightarrow \text{I-LOC}$ ga yuqori, $0 \rightarrow \text{I-LOC}$ ga past ball berishi mumkin.

		joriy teg y_t			
		0	B-LOC	I-LOC	
oldingi teg y_{t-1}	0			✗	$0 \rightarrow \text{I-LOC}$: noto'g'ri
	B-LOC			✓	$\text{B-LOC} \rightarrow \text{I-LOC}$: tabiiy davom
	I-LOC				

Xulosa: CRF teglar orasidagi o'tishlarni hisobga olib, **eng mos butun ketma-ketlikni** tanlaydi. Shu sabab NER da Bi-LSTM + CRF ko'pincha oddiy per-token softmaxdan yaxshiroq ishlaydi.

Ilova S2: zamonaviy NERda subword va Transformer yondashuvi

Bugungi darsda asosiy e'tibor **Bi-LSTM/Bi-LSTM-CRF** modeliga qaratildi. Amaliy NER tizimlarida esa ko'pincha oldindan o'qitilgan **Transformer** modellari ishlatiladi: **mBERT** (*multilingual BERT*), **XLM-R** yoki tilga mos BERT variantlari.

- **Afzallik:** Transformer kontekstli ifoda beradi; shu sabab kamroq teglangan ma'lumotda ham yaxshi boshlang'ich model bo'lishi mumkin.
- **Muammo:** WordPiece/BPE (*Byte Pair Encoding*) tokenizatsiya so'zni **subword**larga, ya'ni so'zosti qismlarga bo'ladi.
- **Amaliy yechim:** IOB2 yorlig'i ko'pincha birinchi subwordga beriladi, qolgan subwordlar esa loss hisobida masklanadi.

Kurs bilan bog'lanish

Bi-LSTM-CRF bizga **ketma-ketlikni tenglash** mantig'ini tushuntiradi: tokenlar, IOB2 teglari, kontekst va entity-darajali baholash. Transformer yondashuvi keyingi bosqichda shu vazifani kuchliroq kontekstli ifodalar bilan bajaradi.